AcessoVoz

Comandos de voz para acessibilidade

Python e redes neurais com um dataset sintetizado

Enzo Toshiyuki Costa
Guilherme Sousa dos Santos

Apresentação em dupla • 28/10/2026

Objetivo do projeto

Leitura com mais autonomia

Explorar comandos de voz para navegar por um texto, ouvir parágrafos e mudar o contraste.

Aplicação proposta para quem encontra barreiras no uso de mouse, teclado ou leitura na tela.

Sete comandos, formas curtas e desconhecido

Comando / forma curta	Ação
ouvir parágrafo / ouvir / ler	Narrar o parágrafo com voz de IA
próximo parágrafo	Selecionar o próximo trecho
parágrafo anterior	Selecionar o trecho anterior
próxima página / próximo / avançar	Virar para a próxima página
página anterior / voltar / anterior	Voltar uma página
ativar contraste / contraste	Alternar o contraste
abrir ajuda / ajuda	Mostrar todos os comandos
desconhecido	**Nenhuma ação executada**

Página e parágrafo são ações independentes. Áudio: oito classes.

Rede neural e aprendizado supervisionado

Rede neural

Um modelo matemático com camadas que combinam números por meio de pesos ajustáveis.

Exemplo rotulado

1. O áudio recebe a classe correta.

2. A rede calcula uma previsão.

3. O treino ajusta os pesos para reduzir o erro.

No projeto, cada áudio tem um dos cinco comandos como rótulo.

Dataset: sete comandos e a categoria desconhecido

220

áudios sintetizados

8 classes

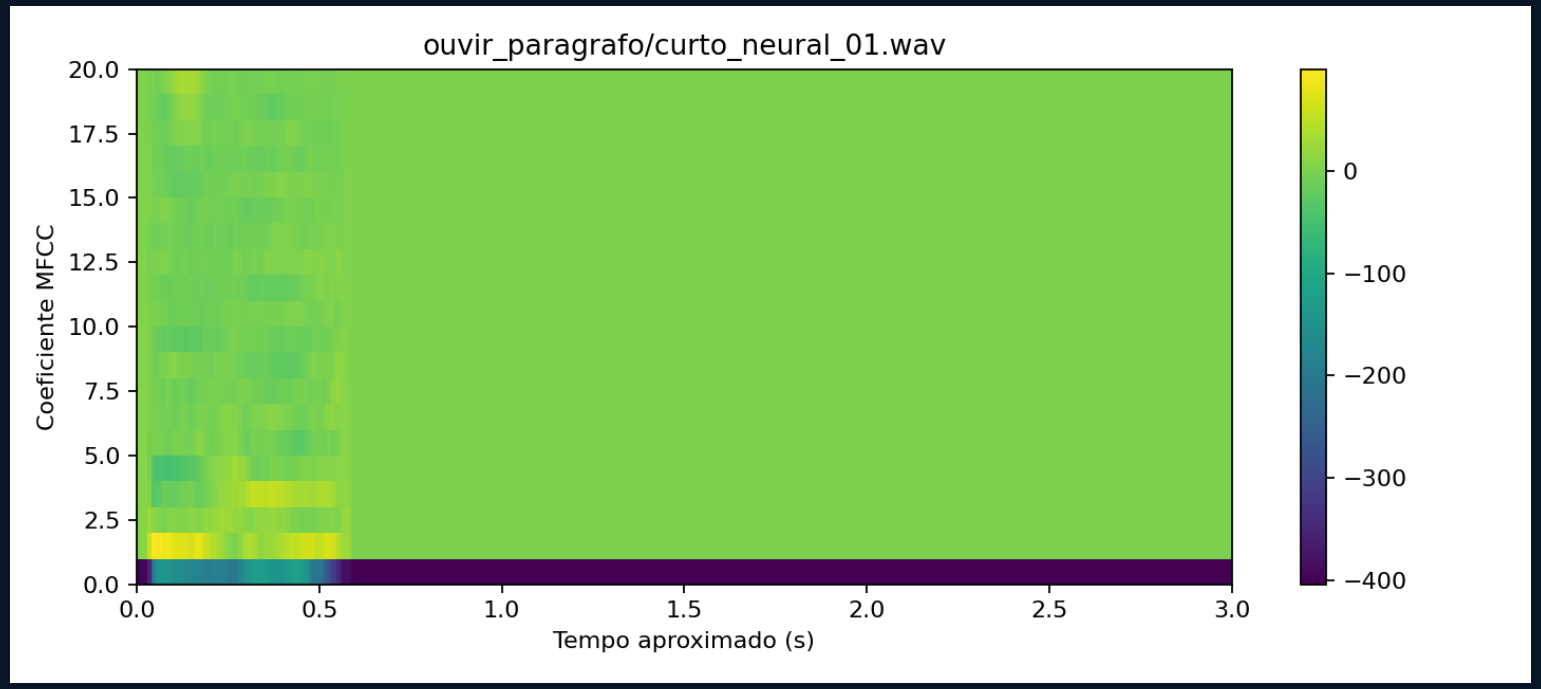
200 áudios dos sete comandos, com frases completas e curtas.

20 frases diferentes na categoria desconhecido.

Duas vozes neurais em português brasileiro.

WAV mono, 16 kHz, 3 segundos. Nenhuma pessoa gravada.

MFCCs: o som representado por números



20 coeficientes

Resumo acústico
em três partes
do tempo.
Média e desvio:
120 características.

Separação dos dados

136

Treino

42

Validação

42

Teste

Perfis de síntese separados entre os conjuntos.

Vozes e motor de síntese compartilhados.

Frases desconhecidas diferentes em treino, validação e teste.

Rede neural em Keras / TensorFlow

Entrada: 120 características e normalização pelo treino.

Camada densa: 64 neurônios com ReLU.

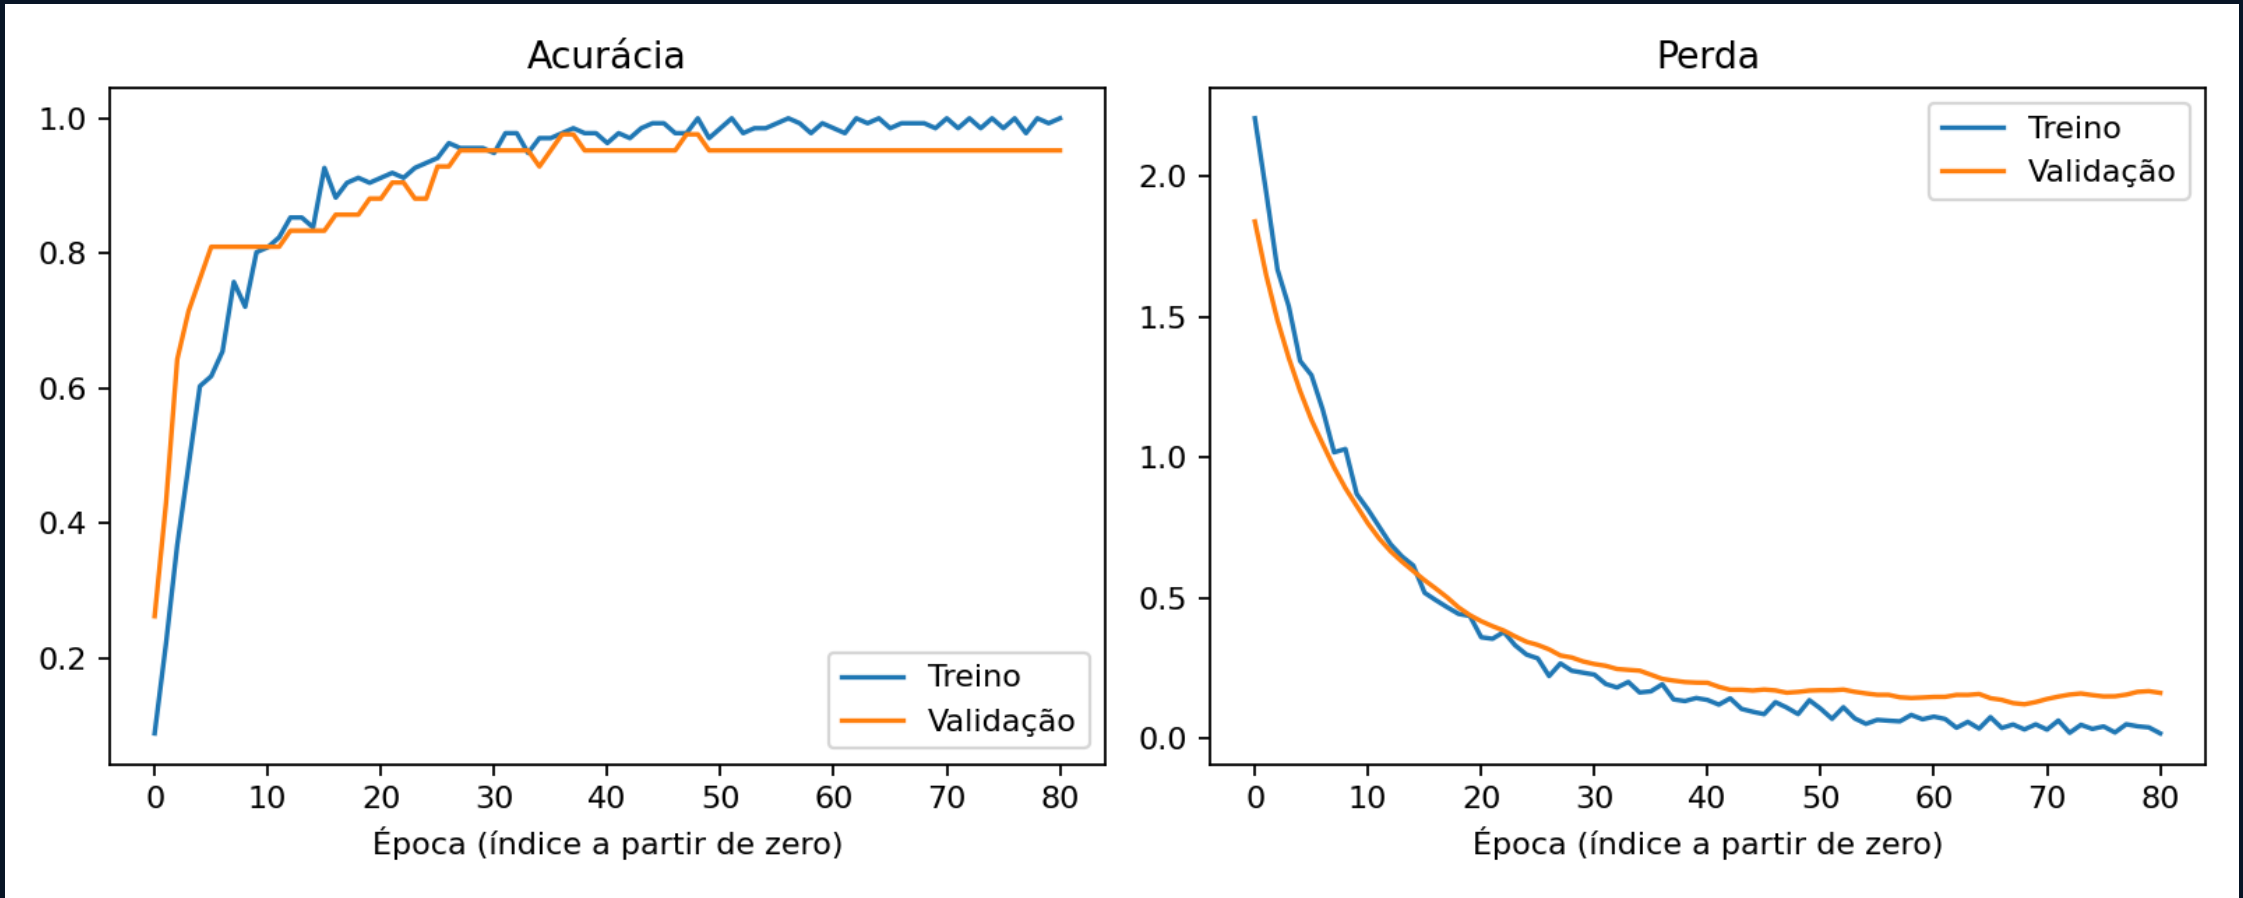
Dropout: 30% durante o treinamento.

Camada densa: 32 neurônios com ReLU.

Saída: oito classes com softmax.

Sete comandos + desconhecido

Resultados do treinamento



81 épocas executadas

Avaliação real: 41 acertos em 42 áudios

97,62%

Acurácia no teste sintético

O teste inclui comandos completos e formas curtas.

Os erros estão registrados em previsoes_teste.csv.

A classe nova ajuda a rejeitar, mas não elimina os erros.

Resultados humanos ainda precisam ser observados na demonstração.

Demonstração: abra o site pelo link

https://enzotoshi.github.io/acessovoz/

1. Permitir o microfone e escolher o modo de reconhecimento.
2. Voz humana: transcrição do navegador + comando interpretado.
3. Rede do projeto: MFCCs e modelo treinado com fala sintética.
4. Falar “ouvir”, “próxima página”, “página anterior” ou “ajuda”.
5. Conferir o texto/previsão e a ação no livro 3D.

A transcrição não é resultado da rede treinada pelo grupo.

Limitações e leitura dos resultados

97,62% é o resultado da rede em 42 áudios sintéticos.

Não foi medida acurácia com vozes humanas nesta revisão.

Ajustamos o volume da captura ao padrão dos áudios de treino.

O modo de transcrição usa o reconhecimento do navegador.

Pode exigir internet e enviar áudio ao provedor do navegador.

Os dois modos podem errar: confira o comando reconhecido.

Para avaliar a rede com pessoas, são necessários testes humanos separados.